

SmartTAR

Version 1.4.0

Technical Architecture, Capabilities and Operating Model

Technická architektura, funkce a provozní model

Purpose / Účel A bilingual technical overview of the STAR archive format, additive generations, global file deduplication, canonical manifest handling, verification, browsing, extraction and transaction safety.
/ Dvojazyčný technický přehled formátu STAR, přídavných generací, globální souborové deduplikace, kanonického manifestu, ověřování, procházení, extrakce a transakční bezpečnosti.

Status: Technical documentation for the validated 1.4.0 design

Date: 25 July 2026

Contents / Obsah

English	Česky
1. Executive overview	1. Stručný přehled
2. Core capabilities	2. Hlavní funkce
3. STAR architecture	3. Architektura STAR
4. Archive creation	4. Vytvoření archivu
5. ADD generations	5. Generace ADD
6. Global deduplication	6. Globální deduplikace
7. Canonical manifest	7. Kanonický manifest
8. Verify, Browse and Extract	8. Verify, Browse a Extract
9. Safety and compatibility	9. Bezpečnost a kompatibilita
10. Operational examples	10. Provozní příklady

Document scope / Rozsah This document explains the format and behavior, not the complete source code API. Values such as block counts and storage savings depend on the selected data and compression method. / Dokument vysvětluje formát a chování, nikoli kompletní API zdrojového kódu. Počty bloků a úspory závisejí na datech a zvolené metodě komprese.

Part I - English

1. Executive overview

SmartTAR is a Windows-oriented archival and backup application that writes a portable .star file built from standard TAR-compatible outer records and independently compressed data blocks. Version 1.4.0 extends the original STAR v1 model with additive generations, global file-level deduplication, multi-root browsing and a canonical single-manifest update model.

Design principle Old data blocks are immutable. New ADD operations append only new unique data and metadata. Byte-identical files become manifest aliases that point directly to an existing physical file target.

Capability	Summary
Portable single file	Archive data, block metadata and the current manifest are contained in one .star file.
Mixed compression generations	Each new ADD operation may use Balanced, Smart, Solid or Store independently.
Global deduplication	Every non-empty byte-identical file can be represented as an alias, regardless of path, generation or selected method.
Selective recovery	Browse and extract a file, folder, ADD batch, ADD root or the complete archive.
Verification	Checks block presence, TAR readability, SHA-256, path safety, alias targets and alias target sizes.
Transactional ADD	Builds and verifies a temporary result before replacing the original archive.

2. Core capabilities

- Create STAR archives from a file or directory using Balanced, Smart, Solid or Store mode.
- Append independent, timestamped ADD generations without recompressing existing blocks.
- Deduplicate identical non-empty files globally by size and SHA-256 content identity.
- Keep logical copies and historical ADD batches while storing each unique file payload only once.
- Browse multi-root archives and restore selected items without extracting everything.
- Perform full extraction to a primary folder and a separate <primary>_add folder.
- Generate persistent TXT reports for Create, ADD, Extract and Verify operations.
- Read earlier released STAR v1 archives; additive STAR v2 requires version 1.4.0 or newer.

3. Compression modes

Mode	Behavior	Typical use
Balanced	Mixed blocks selected from file characteristics; balances speed and ratio.	General archives and mixed application folders.
Smart	Deeper content analysis and maximum-compression preference.	When ratio matters more than creation time.
Solid	A single solid data stream where	Sets with many similar small files.

Mode	Behavior	Typical use
	applicable.	
Store	No payload compression.	Already compressed data, speed-focused capture or controlled testing.

Compression mode is applied only to newly stored unique data. If an ADD generation contains only duplicates, no new data block is required, even if Store or Solid was selected. The generation still receives structural metadata and aliases.

4. STAR archive architecture

```
Outer .star container
blocks/000001_structure.tar...
blocks/000002_compressible.tar.xz
blocks/000003_structure_add001.tar...
...
manifest.json  <- exactly one current manifest, last logical entry
```

The outer container separates structure from payload groups. Data blocks are independently addressable and carry IDs, paths, source-byte counts, file counts, compression methods and SHA-256 values in the manifest. This supports selective streaming, verification and append-only growth.

Layer	Responsibility
Outer STAR/TAR	Packages blocks and the final manifest into one portable file.
Structure blocks	Represent directory trees and empty or structural entries.
Data blocks	Store physically unique file payloads using the selected method.
Manifest	Describes active blocks, roots, aliases, histories, summaries and the canonical tail layout.
Alias catalog	Maps a logical file path to one physically stored target path and records its byte length.

5. Archive creation workflow

```
Analyze source -> classify files -> detect duplicates -> build structure -> create data blocks -> write canonical
manifest -> publish
```

During initial creation, SmartTAR analyzes the source, groups files, omits duplicate payloads from data blocks, and creates a manifest alias for each duplicate. The canonical manifest is written as the final logical outer entry. The manifest includes an outerLayout marker that enables safe replacement during future ADD operations.

6. ADD generation workflow

```
Read current manifest
Extract physical block members for dedup indexing
Prepare ADD/ADD_yyyyMMdd_HH:mm:ss/<source>/...
Deduplicate against all physical files
Compress only remaining unique data
Copy original STAR to transaction temp
Remove old manifest tail from temp
Append new blocks + one merged manifest
Verify temp
Replace original only after Verification: OK
```

Important Existing alias files are not materialized when building the ADD dedup index. This prevents alias-to-alias chains. Every new alias must target a physically stored file.

7. Global file deduplication

SmartTAR 1.4.0 uses full-file content identity. Non-empty files are first grouped by exact byte length. SHA-256 is calculated only for same-size candidates. A matching file is omitted from the new data block and represented by a manifest alias.

Logical path: ADD/ADD_20260725_235138/Test/example.bin
 Physical target: original-root/example.bin
 Stored in manifest: path + target + bytes

Property	Effect
Path independent	Renaming or moving a duplicate does not prevent deduplication.
Generation independent	A duplicate in any later ADD generation can reuse the original physical payload.
Method independent	Balanced, Smart, Solid and Store generations can reuse the same target.
Non-empty files	Dedup threshold is 1 byte. Zero-byte files contain no payload and remain ordinary entries.
Direct targets only	Alias-to-alias chains are rejected during manifest assembly and Verify.

Validated example A 51.30 MB folder containing 69 non-empty files was added again. All 69 files became aliases, the archive grew by only about 12.50 KB, and Verify reported all aliases and blocks as valid. The remaining growth was structural and manifest overhead.

8. Canonical single manifest

New STAR archives contain one current manifest.json as the last logical outer entry. The manifest stores an outerLayout section with a validated truncateOffset that marks the beginning of its replaceable tail record.

```
"outerLayout": {
  "schema": 1,
  "mode": "replaceable-tail-manifest",
  "manifestEntry": "manifest.json",
  "manifestPosition": "last",
  "truncateOffset": <byte offset>,
  "alignmentBytes": 512
}
```

For ADD, SmartTAR copies the original archive to a uniquely named transaction file, validates the layout and offset, truncates only the temporary copy, appends new blocks, calculates a new offset, writes one merged manifest, verifies the result, and only then replaces the original archive.

9. Browse, extraction and restoration layout

Inside Browse
 PrimaryRoot/
 ADD/
 ADD_yyyyMMdd_HH:mm:ss/
 SourceName/
 files and folders

Full extraction
 Destination/PrimaryRoot/
 Destination/PrimaryRoot_add/
 ADD_yyyyMMdd_HH:mm:ss/SourceName/...

Selection	Result
Primary root	Restores only the original primary tree.
ADD	Restores as <primary>_add.
Timestamped batch	Restores only that ADD_yyyyMMdd_HH:mm:ss directory.
Source folder or subfolder	Restores only the selected leaf and descendants.
Single file	Streams only the required block or physical alias target.

10. Verification model

- Every manifest block must exist at a safe relative path.
- Each block must be readable as a TAR payload and match its recorded SHA-256.
- Unsafe archive entries and path traversal are rejected.
- Every alias path and target must be safe.
- Every alias target must be physically present in blocks, not another alias.
- The physical target length must match alias.bytes.
- Canonical archives must contain exactly one manifest as the final logical entry.
- ADD publication occurs only after the temporary archive returns Verification: OK.

11. Transaction safety and resource handling

Control	Purpose
Destination-local temp copy	Protects the original STAR from partial ADD writes.
Unique temp name	Uses archive.star.adding.<GUID>.tmp to avoid collisions.
Free-space precheck	Estimates archive + source + safety reserve before starting transactional copy.
Retry cleanup	Removes failed or cancelled transaction files after worker termination.
Short work paths	Reduces Windows PowerShell 5.1 MAX_PATH pressure.
Stream disposal	File streams use try/finally or C# using blocks.

12. Compatibility

Producer / archive	SmartTAR 1.3.x	SmartTAR 1.4.0
Released STAR v1 archive	Supported	Supported
New 1.4.0 STAR before ADD (v1 + outerLayout)	Expected to remain readable; unknown fields are ignored	Supported
STAR v2 after ADD	Not supported	Supported
Intermediate development formats	Not guaranteed	Not a release compatibility target

Compatibility rule Version 1.4.0 reads released earlier STAR v1 archives. Once ADD upgrades an archive to the multi-root additive STAR v2 model, version 1.4.0 or newer is required.

13. Operational guidance

- Run Verify after important ADD operations and before relying on an archive as the only copy.
- Keep sufficient free space for the transaction copy, new data and safety reserve.
- Do not manually edit manifest.json or blocks inside a STAR archive.
- Keep TXT reports when diagnosing unexpected behavior.
- Use Browse for selective restore and full Extract for complete recovery.
- If an operation is cancelled, confirm that the original archive still passes Verify.

Část II - Český

1. Stručný přehled

SmartTAR je archivní a zálohovací aplikace pro Windows, která vytváří přenositelný soubor .star. Vnější kontejner je založený na záznamech kompatibilních s TARem a obsahuje samostatně komprimované datové bloky. Verze 1.4.0 rozšiřuje původní model STAR v1 o přídatné generace, globální souborovou deduplikaci, vícekořenové procházení a kanonický model jediného manifestu.

Základní princip Staré datové bloky se nemění. Operace ADD připojuje jen nová unikátní data a metadata. Bajtově stejné soubory se zapisují jako aliasy odkazující přímo na existující fyzicky uložený soubor.

Funkce	Shrnutí
Jeden přenositelný soubor	Data, metadata bloků i aktuální manifest jsou v jediném souboru .star.
Kombinace metod	Každá operace ADD může nezávisle použít Balanced, Smart, Solid nebo Store.
Globální deduplikace	Každý neprázdný bajtově shodný soubor může být alias bez ohledu na cestu, generaci nebo metodu.
Selektivní obnova	Lze obnovit soubor, složku, dávku ADD, celý kořen ADD nebo celý archiv.
Ověření	Kontroluje bloky, TAR strukturu, SHA-256, bezpečnost cest, cíle aliasů a jejich velikost.
Transakční ADD	Výsledek se vytvoří a ověří dočasně; originál se nahradí až po úspěchu.

2. Hlavní funkce

- Vytvoření archivu STAR ze souboru nebo složky v režimu Balanced, Smart, Solid nebo Store.
- Připojení samostatných časových generací ADD bez rekompresy starých bloků.
- Globální deduplikace všech neprázdných shodných souborů podle velikosti a SHA-256.
- Zachování logických kopií a historie při jediném fyzickém uložení unikátních dat.
- Procházení archivu a selektivní obnova bez úplné extrakce.
- Úplná extrakce do hlavní složky a samostatné složky <hlavní>_add.
- Trvalé TXT reporty pro Create, ADD, Extract a Verify.
- Čtení vydaných archivů STAR v1; pro aditivní STAR v2 je nutná verze 1.4.0 nebo vyšší.

3. Režimy komprese

Režim	Chování	Typické použití
Balanced	Smíšené bloky podle vlastností souborů; kompromis rychlosti a poměru.	Běžné archivy a smíšené složky.
Smart	Hlubší analýza obsahu a preference maximální komprese.	Když je důležitější poměr než čas.
Solid	Jeden solidní datový proud, pokud je vhodný.	Mnoho podobných malých souborů.

Režim	Chování	Typické použití
Store	Bez komprese dat.	Již komprimovaná data, rychlost nebo řízený test.

Zvolená metoda se použije pouze na nová unikátní data. Pokud je celá dávka ADD duplicitní, nový datový blok nevznikne, i když byl zvolen Store nebo Solid. Přibude pouze struktura a aliasy.

4. Architektura STAR

```
Vnější kontejner .star
blocks/000001_structure.tar...
blocks/000002_compressible.tar.xz
blocks/000003_structure_add001.tar...
...
manifest.json  <- právě jeden aktuální manifest, poslední logická položka
```

Vnější kontejner odděluje strukturu od datových skupin. Datový blok má v manifestu ID, cestu, zdrojovou velikost, počet souborů, kompresní metodu a SHA-256. Díky tomu lze bloky ověřovat, streamovat a doplňovat bez přepisu starých bloků.

Vrstva	Úloha
Vnější STAR/TAR	Spojuje bloky a finální manifest do jednoho souboru.
Strukturální bloky	Uchovávají strom složek a prázdné nebo strukturální položky.
Datové bloky	Uchovávají fyzicky unikátní obsah souborů.
Manifest	Popisuje bloky, kořeny, aliasy, historii, souhrny a koncový layout.
Katalog aliasů	Mapuje logickou cestu na jednu fyzickou cílovou cestu a její velikost.

5. Vytvoření archivu

Analýza zdroje -> klasifikace -> dedup -> struktura -> datové bloky -> kanonický manifest -> publikování

Při vytvoření SmartTAR analyzuje zdroj, sestaví skupiny, vynechá duplicitní obsah z datových bloků a pro duplicity vytvoří aliasy. Manifest je poslední logická položka. Obsahuje také údaj outerLayout pro bezpečnou výměnu při budoucím ADD.

6. Průběh operace ADD

```
Načíst manifest
Rozbalit fyzické členy bloků pro dedup index
Připravit ADD/ADD_yyyyMMdd_HH:mm:ss/<zdroj>/...
Deduplikovat proti všem fyzickým souborům
Komprimovat jen zbývající unikátní data
Zkopírovat originál do transakčního souboru
Odstranit starý koncový manifest pouze z kopie
Připojit nové bloky a jediný sloučený manifest
Verify
Nahradit originál až po Verification: OK
```

Důležité Při tvorbě dedup indexu se staré aliasy fyzicky neobnovují. Tím se zabrání řetězení aliasů. Nový alias smí odkazovat pouze na fyzicky uložený soubor.

7. Globální deduplikace

SmartTAR používá identitu celého souboru. Soubory se nejprve seskupí podle přesné velikosti. SHA-256 se počítá pouze pro kandidáty stejné velikosti. Při shodě se obsah znovu neuloží a vznikne alias v manifestu.

Logická cesta: ADD/ADD_20260725_235138/Test/example.bin
Fyzický cíl: původní-kořen/example.bin
V manifestu: path + target + bytes

Vlastnost	Důsledek
Nezávislost na cestě	Přejmenování nebo přesun nebrání deduplikaci.
Nezávislost na generaci	Pozdější ADD může znovu použít původní fyzická data.
Nezávislost na metodě	Balanced, Smart, Solid i Store mohou sdílet stejný cíl.
Všechny neprázdné soubory	Limit je 1 bajt. Prázdný soubor nemá datový obsah k deduplikaci.
Jen přímé cíle	Řetězce alias -> alias jsou odmítnuty při sestavení i Verify.

Ověřený příklad Identická složka 51,30 MB se 69 neprázdny soubory byla přidána znovu. Všechny 69 souborů se změnilo na aliasy, archiv narostl jen přibližně o 12,50 KB a Verify potvrdil všechny aliasy i bloky. Nárůst tvořila struktura a metadata.

8. Jediný kanonický manifest

Nový archiv STAR obsahuje jediný aktuální manifest.json jako poslední logickou položku. Pole outerLayout obsahuje ověřovaný truncateOffset označující začátek vyměnitelné koncové části.

```
"outerLayout": {
  "schema": 1,
  "mode": "replaceable-tail-manifest",
  "manifestEntry": "manifest.json",
  "manifestPosition": "last",
  "truncateOffset": "<bajtový offset>",
  "alignmentBytes": 512
}
```

Při ADD SmartTAR zkopíruje originál do unikátního transakčního souboru, ověří layout, zkrátí pouze kopii, připojí nové bloky, vypočítá nový offset, zapíše jediný sloučený manifest, ověří výsledek a teprve pak nahradí originál.

9. Browse a extrakce

Uvnitř Browse
HlavníKořen/
ADD/
ADD_yyyyMMdd_HHmss/
NázevZdroje/
soubory a složky

Úplná extrakce
Cíl/HlavníKořen/
Cíl/HlavníKořen_add/
ADD_yyyyMMdd_HHmss/NázevZdroje/...

Výběr	Výsledek
Hlavní kořen	Obnoví pouze původní strom.
ADD	Obnoví se jako <hlavní>_add.
Časová dávka	Obnoví jen vybranou ADD_yyyyMMdd_HHmss.
Zdrojová složka nebo podsložka	Obnoví jen vybranou položku a její potomky.
Jeden soubor	Streamuje jen potřebný blok nebo fyzický cíl aliasu.

10. Model Verify

- Každý blok musí existovat na bezpečné relativní cestě.
- Blok musí být čitelný jako TAR a musí odpovídat SHA-256.
- Nebezpečné cesty a pokusy o průchod mimo cíl jsou odmítnuty.
- Každá cesta aliasu a cíle musí být bezpečná.
- Cíl aliasu musí být fyzicky v blocích, nikoli jiný alias.
- Velikost fyzického cíle musí odpovídat alias.bytes.
- Kanonický archiv musí mít jediný manifest jako poslední položku.
- ADD se publikuje pouze po Verification: OK.

11. Transakční bezpečnost

Ochrana	Účel
Lokální transakční kopie	Chrání originál před neúplným zápisem ADD.
Unikátní název	archive.star.adding.<GUID>.tmp zabraňuje kolizím.
Kontrola místa	Odhadne archiv + zdroj + rezervu před kopírováním.
Opakovaný úklid	Po chybě nebo zrušení odstraní transakční soubor.
Krátké pracovní cesty	Snižují problém MAX_PATH ve Windows PowerShellu 5.1.
Uvolnění streamů	FileStream je uzavřen v try/finally nebo using.

12. Kompatibilita

Archiv / producent	SmartTAR 1.3.x	SmartTAR 1.4.0
Vydaný STAR v1	Podporováno	Podporováno
Nový STAR 1.4.0 před ADD (v1 + outerLayout)	Očekávaná čitelnost; neznámá pole se ignorují	Podporováno
STAR v2 po ADD	Nepodporováno	Podporováno
Vývojové meziformáty	Bez záruky	Nejsou cílem kompatibility vydání

Pravidlo kompatibility Verze 1.4.0 čte vydané starší archivy STAR v1. Po povýšení archivu operací ADD na vícekořenový aditivní STAR v2 je nutná verze 1.4.0 nebo novější.

13. Doporučený provoz

- Po důležitém ADD proveďte Verify, zejména pokud má být STAR jedinou kopií.
- Ponechte dostatek volného místa pro transakční kopii, nová data a rezervu.
- Neupravujte ručně manifest.json ani bloky uvnitř STARu.
- Pro diagnostiku uchovávejte TXT reporty.
- Pro selektivní obnovu použijte Browse, pro úplnou obnovu Extract.
- Po zrušené operaci ověřte, že původní archiv stále projde Verify.

14. Shrnutí

SmartTAR 1.4.0 kombinuje přenositelný jednosouborový archiv, nezávisle komprimované bloky, globální souborovou deduplikaci, nezávislé generace ADD, jediný vyměnitelný manifest, selektivní obnovu a úplné ověřování integrity. Výsledkem je formát vhodný pro postupné zálohování i archivaci s možností kombinovat různé kompresní režimy bez ukládání shodných dat podruhé.

Stav dokumentu Dokument popisuje ověřený návrh SmartTAR 1.4.0 k 25. červenci 2026. Implementační detaily se mohou v budoucích verzích změnit při zachování kompatibility formátu.